



POLITECHNIKA WARSZAWSKA  
Wydział Elektroniki i Technik Informacyjnych  
Instytut Informatyki

Rok akademicki 2013/2014

## PRACA DYPLOMOWA MAGISTERSKA

Michał Aniserowicz

**[TODO] (Generator aplikacji opartych o architekturę CQRS?)**

Praca wykonana pod kierunkiem  
dra inż. Jakuba Koperwasa

Ocena: .....

.....

*Podpis Przewodniczącego Komisji  
Egzaminu Dyplomowego*

Kierunek: Informatyka  
Specjalność: Inżynieria Systemów Informatycznych  
Data urodzenia: 1990.02.14  
Data rozpoczęcia studiów: 2009.10.01

## Życiorys

Urodziłem się 14.02.1990 w Białymstoku. Wykształcenie podstawowe odebrałem w latach 1997-2006 w Publicznej Szkole Podstawowej nr 9 w Białymstoku i Publicznym Gimnazjum nr 2 im. 42 Pułku Piechoty w Białymstoku. W latach 2006-2009 uczęszczałem do III Liceum Ogólnokształcącego im. K. K. Baczyńskiego w Białymstoku. Od roku 2009 jestem studentem studiów dziennych pierwszego stopnia na kierunku Informatyka na wydziale Elektroniki i Technik Informacyjnych Politechniki Warszawskiej. W marcu 2012 roku podjąłem pracę jako programista w firmie Fun and Mobile, gdzie po kilku miesiącach zostałem zastępcą przywódcy zespołu, do którego należę również obecnie. Moją pasją jest programowanie aplikacji w technologii .NET Framework.

.....

Podpis studenta

Egzamin dyplomowy:

Złożył egzamin dyplomowy w dniu: .....

z wynikiem: .....

Ogólny wynik studiów: .....

Dodatkowe uwagi i wnioski Komisji: .....

.....

**Streszczenie**

TODO

**TODO (eng. title)**

**Summary**

TODO

# Spis treści

<b>1</b>	<b>Wstęp</b>	<b>4</b>
<b>2</b>	<b>Duplikacja</b>	<b>5</b>
2.1	Rodzaje duplikacji . . . . .	5
2.2	Skutki występowania duplikacji . . . . .	8
2.3	Rozwiązanie: utrzymywanie listy zduplikowanych fragmentów . . . . .	8
2.4	Rozwiązanie: skrypty automatyzujące rutynowe czynności . . . . .	9
2.5	Rozwiązanie: generyczna implementacja . . . . .	9
2.6	Rozwiązanie: użycie generatorów . . . . .	10
2.7	Rozwiązanie: pojedynczy generator wszystkich artefaktów systemu . . . . .	12
2.8	Podsumowanie . . . . .	12
<b>3</b>	<b>Sprecyzowanie problemu</b>	<b>14</b>
<b>4</b>	<b>Generacja</b>	<b>15</b>
<b>5</b>	<b>Założenia dotyczące rdzenia narzędzia</b>	<b>16</b>
5.1	Podstawowe założenia dotyczące rdzenia narzędzia . . . . .	16
5.2	Kroki generacji . . . . .	16
5.3	Organizacja plików źródłowych i wynikowych . . . . .	18
5.4	Sposób zdefiniowania dziedziny aplikacji . . . . .	20
5.5	Czy wymagać stworzenia schematu definicji dziedziny aplikacji? . . . . .	24
5.6	Wybór silnika do generacji kodu . . . . .	26
5.7	Podsumowanie . . . . .	27
<b>6</b>	<b>Sprecyzowanie typu generowanych aplikacji</b>	<b>29</b>
6.1	Wybór typu aplikacji . . . . .	29
6.2	CQRS . . . . .	30
6.3	Event Sourcing . . . . .	33
6.4	NoSQL . . . . .	35
6.5	Cassandra . . . . .	38
<b>7</b>	<b>Implementacja generatora aplikacji pojedynczego typu</b>	<b>41</b>
<b>8</b>	<b>Ocena rozwiązania</b>	<b>43</b>
<b>9</b>	<b>Podsumowanie</b>	<b>44</b>

# Rozdział 1

## Wstęp

# Rozdział 2

## Duplikacja

Zasada “DRY” (ang. *“Don’t Repeat Yourself”*), sformułowana przez Andrew Hunt’a i David’a Thomas’a, mówi: “Każda porcja wiedzy powinna mieć pojedynczą, jednoznaczną i autorytatywną reprezentację w systemie” [1]. Poprawne jej stosowanie skutkuje osiągnięciem stanu, w którym pojedyncza zmiana zachowania systemu wymaga modyfikacji tylko jednego fragmentu reprezentacji wiedzy. Należy podkreślić, że autorzy tej zasady przez “reprezentację wiedzy” rozumieją nie tylko kod źródłowy tworzony przez programistów systemu. Zaliczają do niej również dokumentację systemu, strukturę bazy danych przez niego używanej oraz inne artefakty powstające w procesie wytwarzania oprogramowania (np. scenariusze testów akceptacyjnych), a nawet czynności wykonywane rutynowo przez programistów.

Celem stosowania zasady “DRY” jest unikanie duplikacji wiedzy zawartej w systemie. Duplikacją określa się fakt występowania w systemie dwóch reprezentacji tej samej porcji wiedzy. Należy wyjaśnić, że wielokrotne występowanie nazw klas lub zmiennych (bądź innych identyfikatorów) w kodzie programu nie jest duplikacją - identyfikatory nie są reprezentacją wiedzy, a jedynie odnośnikami do wiedzy reprezentowanej przez artefakty, na które wskazują.

### 2.1 Rodzaje duplikacji

Wyróżnia się cztery rodzaje duplikacji ze względu na przyczynę jej powstania [1]:

- duplikacja wymuszona (ang. *imposed duplication*) - pojawia się, gdy programista świadomie duplikuje kod aplikacji (lub inną reprezentację wiedzy) uznając, że w danej sytuacji nie jest możliwe uniknięcie duplikacji;
- duplikacja niezamierzona (ang. *inadvertent duplication*) - występuje wtedy, gdy programista nie jest świadomy, że jego działania prowadzą do powstania duplikacji;
- duplikacja niecierpliwa (ang. *impatient duplication*) - jest wynikiem niedbalstwa programisty; ma miejsce w sytuacji, gdy programista, napotkawszy problem, świadomie wybierze rozwiązanie najprostsze, ale prowadzące do powstania duplikacji;

- duplikacja pomiędzy programistami (ang. *interdeveloper duplication*) - pojawia się, gdy kilku programistów tworzących tę samą aplikację wzajemnie duplikuje tworzony kod lub tworzy niezależne reprezentacje tej samej wiedzy.

Duplikacja może występować w różnych postaciach:

### 2.1.1 Duplikacja czynności wykonywanych przez programistów

Do rutynowych czynności wykonywanych podczas pracy programisty należą wszelkiego rodzaju aktualizacje: struktury bazy danych rezydującej na maszynie programisty czy wersji tworzonego oprogramowania zainstalowanej w środowisku testowym lub produkcyjnym.

Czynności te zwykle składają się z kilku kroków. Przykładowo, na aktualizację bazy danych może składać się:

1. Usunięcie istniejącej bazy.
2. Stworzenie nowej bazy.
3. Zainicjalizowanie struktury nowej bazy przy pomocy zaktualizowanego skryptu DLL (*Data Definition Language*).
4. Wypełnienie nowej bazy danymi przy pomocy zaktualizowanego skryptu DML (*Data Manipulation Language*).

Jeśli wszystkie z tych kroków wykonywane są ręcznie, to mamy do czynienia z duplikacją - każdy programista w zespole, zamiast tylko odwoływać się do wiedzy o tym, jak zaktualizować bazę danych, musi posiadać tę wiedzę i wielokrotnie wcielać ją w życie krok po kroku.

### 2.1.2 Duplikacja kodu źródłowego aplikacji

Programistom niejednokrotnie zdarza się spowodować duplikację w kodzie źródłowym tworzonych programów. Powielone fragmenty kodu są zazwyczaj niewielkie, a podzielić je można na następujące kategorie [3]:

- prosta duplikacja wyrażeń (ang. *basic literal duplication*) - najprostszy rodzaj duplikacji; obejmuje fragmenty kodu, których treść jest identyczna (przykład: dwie identyczne metody umiejscowione w różnych modułach systemu);
- parametryczna duplikacja wyrażeń (ang. *parametric literal duplication*) - obejmuje fragmenty kodu, których treść różni się jedynie typami danych, na których te fragmenty operują;
- duplikacja strukturalna (ang. *structural duplication*) - obejmuje fragmenty kodu, które mają ten sam schemat działania, ale różnią się pojedynczymi instrukcjami (przykład: dwie pętle iterujące po tej samej kolekcji z tym samym warunkiem stopu, ale wykonujące różne operacje na elementach kolekcji);

- duplikacja czasowa (ang. *temporal duplication*) - określa fragment kodu, który jest niepotrzebnie wykonywany wiele razy (przykład: zliczenie elementów kolekcji podczas każdego sprawdzenia warunku stopu pętli iterującej po tej kolekcji);
- duplikacja intencji (ang. *duplication of intent*) - występuje, gdy dwóch programistów umieści w różnych modułach aplikacji dwa fragmenty, których wynik działania (ale niekoniecznie treść) jest identyczny (jest to jeden z przypadków duplikacji pomiędzy programistami).

### 2.1.3 Duplikacja opisu dziedziny aplikacji

W każdej aplikacji obiektowej korzystającej z bazy danych opis dziedziny aplikacji występuje w co najmniej dwóch miejscach. Te miejsca to:

- struktura bazy danych (DDL);
- definicje klas w kodzie źródłowym aplikacji.

Kolejnym typowym miejscem, w którym umieszcza się informacje o dziedzinie aplikacji jest jej dokumentacja.

W miarę rozrastania się systemu i powstawania kolejnych funkcjonalności i komponentów, pojawia się tendencja do powielania całości bądź części definicji dziedziny w różnych modułach. Dotyczy to głównie tych modułów, których zadaniem jest obróbka tych samych danych, ale w różny sposób. Przykładowo, aplikacja może pozwalać na dostęp do przechowywanych danych na następujące sposoby:

- wyświetlać je na stronach WWW,
- udostępniać je poprzez usługi sieciowe jako API (*Application Programming Interface*),
- umożliwiać ich eksport do arkusza kalkulacyjnego.

Komponenty realizujące te funkcjonalności mogą korzystać z pojedynczej implementacji dziedziny. Może to jednak nie być pożądane, szczególnie w przypadku, gdy każdy ze sposobów udostępnia inny zestaw danych. Przykładowo, strony WWW mogą wyświetlać podstawowe dane każdej encji będącej częścią dziedziny, podczas gdy API udostępnia pełne dane wszystkich encji, a eksport do arkusza kalkulacyjnego udostępnia pełne dane tylko niektórych encji.

W takim przypadku komponent odpowiedzialny za API operuje na pełnej dziedzinie, a komponenty stron WWW i eksportu do arkusza kalkulacyjnego - jedynie na jej fragmentach. Jeśli każdy z tych komponentów posiada niezależną implementację dziedziny aplikacji, to mamy do czynienia z duplikacją.



## 2.2 Skutki występowania duplikacji

Pojawienie się duplikacji w systemie ma zazwyczaj szkodliwe skutki. Rozprzestrzenia się ona tym szybciej, a wyrządzane szkody są tym dotkliwsze, im większy jest rozmiar systemu.

Najbardziej oczywistym skutkiem występowania duplikacji jest wydłużenie się czasu poświęcanego przez programistów na nieskomplikowane lub powtarzalne zadania. Przykładowo, nieznanomość kodu współdzielonego przez wszystkie komponenty systemu (tzw. rdzenia, ang. *core*) powoduje, że programiści niepotrzebnie spędzają czas na implementowaniu podstawowych funkcji, które są już dostępne w rdzeniu systemu. Innym przykładem może być praktyka ręcznego wykonywania czynności, które mogą być wykonywane automatycznie, w tle.

Po drugie, pojedyncza porcja wiedzy jest reprezentowana w wielu miejscach, a więc zmiana pojedynczego zachowania systemu wymaga modyfikacji wielu jego modułów. Wprowadzając dowolną modyfikację, programista musi ręcznie zlokalizować wszystkie miejsca wymagające zaktualizowania. Problem ten jest najbardziej odczuwalny podczas naprawy zgłoszonych błędów: będąc świadomym występowania duplikacji kodu, programista naprawiający błąd musi pamiętać, że poprawiany przez niego fragment może być powielony w wielu miejscach w systemie. Wszystkie te miejsca musi zlokalizować i poprawić [4]. Jeśli tego nie zrobi, w systemie pozostaną sprzeczne ze sobą reprezentacje danej wiedzy, a kolejni programiści nie będą świadomi, która reprezentacja jest poprawna. W dłuższej perspektywie taka sytuacja prowadzi do pojawienia się kolejnych błędów.

Po trzecie, duplikacja powoduje zbędne powiększenie rozmiarów systemu. Kod, w którym występują zduplikowane fragmenty jest dłuższy, a przez to mniej czytelny. Co więcej, zwiększona ilość kodu powoduje niepożądane zwiększenie rozmiarów plików wchodzących w skład systemu.

Należy również zwrócić uwagę na zagrożenie, jakie niesie ze sobą wystąpienie pojedynczej duplikacji, której istnienie zostanie zaaprobowane przez programistów wchodzących w skład zespołu tworzącego projekt. Może to spowodować osłabienie dyscypliny w zespole, a w efekcie doprowadzić do pojawienia się kolejnych duplikacji, a także innych złych praktyk programistycznych. Pojedyncze wystąpienie tego zjawiska może więc doprowadzić do rozprzestrzenia się innych niepożądanych zjawisk i pogorszenia jakości całego systemu [2].

## 2.3 Rozwiązanie: utrzymywanie listy zduplikowanych fragmentów

Najprostszym, a zarazem najbardziej naiwnym sposobem na zniwelowanie skutków duplikacji może być utrzymywanie listy fragmentów systemu, w których duplikacja występuje. Przykładowo, zespół może przygotować listę miejsc, które należy zmodyfikować, jeśli pojedyncza encja zostanie wzbogacona o nowe pole. Na takiej liście znalazłaby się struktura bazy danych, implementacja modelu danych w kodzie źródłowym programu, dokumentacja systemu, itd.

Takie podejście ma jednak istotne wady:

- rozwiązanie to nie powstrzymuje programistów przed wprowadzaniem kolejnych duplikacji, a wręcz na to przyzwala;

- pojawienie się nowego miejsca występowania pól encji (np. alternatywnej implementacji modelu danych) wymaga zaktualizowania listy; niezaktualizowana lista może skutkować pominięciem nowych miejsc w szacunkach dotyczących czasu potrzebnego na implementację nowych funkcjonalności i w samej implementacji tych funkcjonalności;
- rozwiązanie to niweluje tylko drugi z wymienionych skutków występowania duplikacji - programista nie musi samodzielnie szukać miejsc, w których powinien wprowadzić modyfikacje.

## 2.4 Rozwiązanie: skrypty automatyzujące rutynowe czynności

Wiele czynności wykonywanych przez programistów da się zautomatyzować, tworząc skrypty je wykonujące. Przykłady:

- wszystkie kroki składające się na czynność aktualizacji schematu bazy przedstawone w sekcji 2.1.1 mogą być wykonywane przez pojedynczy skrypt powłoki korzystający z kilku skryptów DDL i DML;
- operacja instalacji nowej wersji systemu na środowisku testowym lub produkcyjnym nie musi wiązać się z ręcznym przesyłaniem plików systemu na serwer FPT zdalnej maszyny - może odbywać się automatycznie, po uruchomieniu odpowiedniego skryptu lub zarejestrowaniu zmiany kodu źródłowego w systemie kontroli wersji [5].

Taka automatyzacja ma wiele zalet, w tym:

- w trakcie działania skryptu w tle, programista może skupić się na innych zadaniach,
- wiedza na temat kroków składających się na daną czynność jest reprezentowana w jednym miejscu (skrypcie),
- programiści lub inne skrypty odwołują się do tej wiedzy poprzez jej identyfikator (nazwę lub ścieżkę w systemie plików).

Należy jednak zauważyć, że podejście to rozwiązuje jedynie problem duplikacji czynności wykonywanych przez programistów. Pozostałe postacie duplikacji nie mogą być zniwelowane w ten sposób.

## 2.5 Rozwiązanie: generyczna implementacja

Rozwiązaniem problemu duplikacji kodu źródłowego aplikacji może być generyczna implementacja aplikacji. W językach obiektowych jest ona możliwa do osiągnięcia na kilka sposobów:

### 2.5.1 Dziedziczenie

Podstawowym sposobem na uniknięcie duplikacji w kodzie aplikacji wykorzystujących języki obiektowe jest dziedziczenie. Metody wspólne dla rodzin klas obiektów są umieszczane w ich klasach bazowych. Pozwala to uniknąć podstawowej duplikacji wyrażeń (patrz: sekcja 2.1.2).

### 2.5.2 Typy szablonowe i generyczne

Innych rodzajów duplikacji - parametrycznej duplikacji wyrażeń i duplikacji strukturalnej - można uniknąć poprzez zastosowanie typów generycznych i szablonów klas. Kod o tej samej strukturze i działaniu, ale operujący na danych innego typu, może być zamknięty w pojedynczej klasie generycznej.

### 2.5.3 Refleksja

W sytuacjach, w których występuje potrzeba zaimplementowania podobnej funkcjonalności dla kilku typów obiektów, które nie należą do jednej rodziny, można skorzystać z mechanizmu refleksji. Pozwala on osiągnąć rezultaty podobne do tych oferowanych przez klasy bazowe i typy generyczne.

Należy podkreślić, że przedstawione propozycje rozwiązują jedynie problem duplikacji kodu źródłowego aplikacji.

## 2.6 Rozwiązanie: użycie generatorów

Rozwiązaniem pozwalającym na uniknięcie duplikacji opisu dziedziny aplikacji jest zastosowanie różnego typu generatorów.

Należy wyjaśnić, że kodu źródłowego (bądź innych artefaktów) wygenerowanego na podstawie innego kodu nie uznaje się za duplikację. Powodem jest to, że jeśli na podstawie danego fragmentu kodu generowanych jest wiele artefaktów, to aby wprowadzić zmiany we wszystkich tych artefaktach, należy jedynie zmodyfikować źródłowy fragment kodu i uruchomić proces generacji. Za “pojedynczą, jednoznaczną i autorytatywną” reprezentację danej porcji wiedzy (patrz: Zasada “DRY”) uznaje się w tym przypadku źródłowy fragment kodu.

### 2.6.1 Generator modelu dziedziny aplikacji na podstawie struktury bazy danych

Najpowszechniejszym przykładem użycia generatorów kodu jest wykorzystanie generatora zestawu klas wchodzących w skład modelu dziedziny aplikacji na podstawie struktury bazy danych używanej przez tę aplikację. Takie podejście nosi nazwę “najpierw baza danych” (ang. *Database First*).

Przykładami narzędzi umożliwiającą taką generację kodu są:

- EntityFramework [6] - rozbudowane narzędzie ORM (ang. *Object-Relational Mapping*) przeznaczone na platformę .Net;
- SQLMetal [7] - narzędzie dla platformy .Net, którego jedynym zadaniem jest generacja kodu źródłowego klas na podstawie struktury bazy danych;
- Django [8] - platforma aplikacji webowych dla języka Python.

### 2.6.2 Generator struktury bazy danych na podstawie modelu dziedziny aplikacji

Podjęciem przeciwnym dla *“Database First”* jest podejście *“najpierw kod”* (ang. *Code First*). Jak sama nazwa wskazuje, generatory tego typu generują strukturę bazy danych na podstawie klas należących do implementacji modelu w kodzie źródłowym aplikacji.

Przykłady generatorów *“Code First”* to:

- Hibernate [9] - narzędzie ORM dla platform Java i .Net;
- EntityFramework (patrz: sekcja 2.6.1);
- Django (patrz: sekcja 2.6.1).

### 2.6.3 Generator dokumentacji

Duplikacji opisu dziedziny aplikacji w jej dokumentacji można uniknąć poprzez zastosowanie narzędzi generujących tę dokumentację na podstawie kodu źródłowego aplikacji. Generatory tego rodzaju wymagają umieszczania w kodzie źródłowym specjalnie sformatowanych komentarzy, na podstawie których są w stanie wygenerować dokumentację w kilku formatach, takich jak PDF czy HTML. Przykłady takich narzędzi to:

- Doxygen [10] - popularne narzędzie obsługujące wiele języków programowania (w tym C++, Java C#), wspierające wiele formatów dokumentacji (w tym HTML, PDF, LaTeX, XML);
- JavaDoc [11] - generator dedykowany językowi Java, domyślnie wspiera jedynie format HTML;
- C# XML Documentation [12] - format tworzenia dokumentacji wbudowany w język C#, na podstawie którego generowana jest dokumentacja w formacie XML;
- pydoc [13] - narzędzie będące częścią standardowego zestawu narzędzi deweloper-  
skich języka Python; wspiera format tekstowy i HTML.

### 2.6.4 Inne generatory

Istnieje wiele innych generatorów, należących do typu programowania nazywanego programowaniem automatycznym (ang. *automatic programming*) [14]. Jednakże większość z nich, tak jak powyższe przykłady, eliminuje tylko pojedyncze rodzaje duplikacji.

Warto zwrócić uwagę na fakt, że różne typy generatorów za źródło danych obierają sobie różne definicje dziedziny: np. generator *Database First* bazuje na strukturze bazy danych, a generator dokumentacji - na kodzie źródłowym aplikacji. Używanie wielu różnych generatorów usuwających pojedyncze rodzaje duplikacji w końcu doprowadziłoby do powstania “łańcucha” generatorów, w którym wynik działania jednego generatora byłby źródłem danych dla innego. Takie rozwiązanie mogłoby być trudne w utrzymaniu.

## 2.7 Rozwiązanie: pojedynczy generator wszystkich artefaktów systemu

Przedstawione rozwiązania mają pewne wspólne wady. Po pierwsze, wszystkie z nich usuwają tylko pojedyncze rodzaje duplikacji. Aby całkowicie wyeliminować duplikację z systemu, należałoby by użyć prawie wszystkich z nich.

Po drugie, rozwiązania zwalczające duplikację czynności wykonywanych przez programistów i duplikacje kodu źródłowego aplikacji nie są rozwiązaniami prewencyjnymi - nie zapobiegają pojawianiu się nowych duplikacji. To, czy nowa rutynowa czynność zostanie zautomatyzowana przy pomocy skryptu powłoki, i czy nowy moduł aplikacji zostanie zaimplementowany w sposób generyczny, zależy jedynie od dyscypliny i dbałości zespołu tworzącego system. Aby uniknąć takiej sytuacji, wydaje się, że mechanizmy niwelujące duplikację powinny leżeć u podstawy systemu - tak, aby programiści intuicyjnie korzystali z nich, wprowadzając nowe czynności lub aktualizując dziedzinę aplikacji.

Odpowiednim rozwiązaniem wydaje się być zastosowanie pojedynczego generatora potrafiącego wygenerować wszystkie potrzebne w systemie artefakty. Powstanie takiego generatora dającego się zastosować w każdym projekcie jest jednak bardzo mało prawdopodobne, ponieważ:

- każdy projekt ma inne wymagania odnośnie wygenerowanych artefaktów;
- prawdopodobne nie istnieje format, który pozwalałby zdefiniować każdą dziedzinę w najlepszy dla niej - tj. najbardziej naturalny, a przy tym pozbawiony duplikacji - sposób.

## 2.8 Podsumowanie

Jak widać, powszechnie dostępne są jedynie rozwiązania pozwalające wyeliminować pojedyncze rodzaje duplikacji. Nie jest jednak dostępny pojedynczy, spójny sposób na wyeliminowanie duplikacji w obrębie całego systemu. Odpowiednim rozwiązaniem wydaje się być połączenie kilku z wyżej przedstawionych sposobów. W dalszej części pracy podjęta zostanie próba stworzenia takiego rozwiązania. Zostanie ono oparte o generację kodu,

a głównym założeniem jest skonstruowanie go w taki sposób, aby pozwolić na usunięcie jak największej liczby rodzajów duplikacji patrząc zarówno z perspektywy ich postaci, jak i przyczyn powstawania (patrz: sekcja 2.1).

## Rozdział 3

# Sprecyzowanie problemu

Celem praktycznej części niniejszej pracy jest opracowanie narzędzia pozwalającego w jak największym stopniu unikać duplikacji podczas tworzenia aplikacji. Narzędzie to będzie oparte o mechanizmy generacji kodu źródłowego oraz innych artefaktów systemu.

Generacja została wybrana jako rozwiązanie problemu duplikacji dlatego, że pozwala zredukować duplikację nie tylko w kodzie źródłowym aplikacji, a w obrębie całego systemu. Co więcej, zastosowanie generacji u podstawy systemu może zapobiec pojawianiu się duplikacji w przyszłości - gdy pojawi się potrzeba stworzenia nowej funkcjonalności, nowego modułu aplikacji bądź nowego artefaktu systemu, programiści prawdopodobnie najpierw spróbują zaimplementować tę nową część systemu tak, aby była generowana na podstawie już istniejącej bazy.

Należy zaznaczyć, że od narzędzia będącego celem pracy nie jest wymagana całkowita eliminacja duplikacji w systemie. Główną postacią duplikacji, która będzie przedmiotem działania narzędzia jest duplikacja dziedziny aplikacji. Wybór padł na tę właśnie postać dlatego, że przejawia się ona w największym zakresie systemu. Co więcej, użycie mechanizmów generacji nie przekreśla eliminacji innych postaci duplikacji. Przykładowo, skrypty powłoki automatyzujące czynności wykonywane przez programistów również mogą być generowane lub mogą działać na wygenerowanych plikach - wtedy tym łatwiej będą się dostosowywać do zmian w systemie. Niektóre fragmenty kodu źródłowego logiki biznesowej lub testów jednostkowych aplikacji również mogą być generowane. Jednak uwaga poświęcona zostanie głównie definicji dziedziny aplikacji.

# Rozdział 4

## Generacja

- kiedy to się opłaca, a kiedy może powodować problemy
- generacja aktywna vs pasywna
- przykłady konkretnych dużych generatorów
- albo typów
  - na podstawie szablonu
  - z CodeDom
  - inne
- wniosek: żaden generator nie będzie jednocześnie bogaty w funkcjonalności i dobry dla każdego typu aplikacji
- zatem: rozwiązanie podzielę na dwie części
  - rdzeń narzędzia do generacji
  - generator aplikacji jednego typu



## Rozdział 5

# Założenia dotyczące rdzenia narzędzia

Przed przystąpieniem do prac nad generatorem aplikacji konkretnego typu, należy sformułować założenia dotyczące komponentu realizującego sam proces generacji artefaktów systemu, nazwanego rdzeniem narzędzia.

### 5.1 Podstawowe założenia dotyczące rdzenia narzędzia

O ile elastyczność generatora konkretnego typu aplikacji może być ograniczona, o tyle rdzeń powinien być na tyle uniwersalny, by mógł być użyty w celu wygenerowania wielu rodzajów plików tekstowych, w tym kodu źródłowego w dowolnym języku, skryptów DLL, skryptów powłoki, dokumentacji w formacie HTML lub XML itd. Wszystkie rodzaje plików powinny być generowane w ten sam sposób (np. na podstawie szablonów napisanych w jednym języku, takim jak xslt [15]), tak aby programista korzystający z komponentu nie musiał poznawać całej gamy języków lub narzędzi używanych do tworzenia szablonów generacji. Pożądaną funkcjonalnością jest możliwość łatwiej wymiany domyślnie używanego rodzaju szablonów na inny, tak aby użytkownik mógł w łatwy sposób użyć w nim szablonów stworzonych w języku, który zna najlepiej. Co więcej, rdzeń narzędzia nie powinien narzucać sposobu formatowania danych wejściowych (w tym przypadku - opisu dziedziny aplikacji).

Dla wygody autora narzędzia zakłada się, że zarówno jego rdzeń jak i generator aplikacji konkretnego typu zostanie stworzony w technologii .NET Framework

### 5.2 Kroki generacji

Generacja odbywać się będzie w następujących krokach:

### 5.2.1 Wczytanie definicji dziedziny aplikacji

Komponent na wejściu przyjmował będzie ścieżkę do pliku lub katalogu źródłowego (patrz: sekcja 5.3). Każdy plik katalogu źródłowego zostanie odwiedzony przez generator, a jego treść zostanie zdeserializowana do obiektu odpowiadającej mu klasy.

### 5.2.2 Zdeserializowanie definicji dziedziny aplikacji

Jak wymieniono w założeniach dotyczących rdzenia generatora (patrz: sekcja 5.1), format opisu dziedziny aplikacji nie będzie narzucony z góry. Każdy plik źródłowy może być zapisany w innym formacie (np. XML lub JSON). Domyślnie wspierany będzie jeden format (patrz: sekcja 5.4), a użytkownik generatora będzie mógł dla każdego pliku źródłowego określić wybrany i dostarczony przez siebie sposób deserializacji.

Zdeserializowany obiekt dziedziny może posłużyć jako wskazanie na kolejne pliki reprezentujące elementy dziedziny. Przykładem obrazującym potrzebę takiego działania może być sytuacja, w której dany plik zawiera ogólne informacje na temat encji, a pliki w podkatalogu sąsiadującym z tym plikiem zawierają definicje poszczególnych pól danej encji (patrz: sekcja 5.3.3). Wtedy wczytanie i deserializacja opisu pól encji odbędzie się dopiero po zdeserializowaniu opisu samej encji i na tej podstawie określeniu, który katalog zawiera kolejne pliki opisujące jej pola.

### 5.2.3 Wyodrębnienie jednostek generacji

Po uzyskaniu kompletnego obiektu - lub kolekcji obiektów - opisującego dziedzinę aplikacji, tzn. po zdeserializowaniu wszystkich plików zawierających dziedzinę aplikacji, generator będzie musiał przygotować kolejne obiekty, które będą podstawą do wygenerowania plików wynikowych. Obiekty te nazwano jednostkami generacji. Jednostką generacji może być na przykład opis pojedynczej encji dziedziny aplikacji lub, bardziej szczegółowo, pojedynczej tabeli bazy danych.

Aby zachować elastyczność, krok ten będzie musiał być zaimplementowany po stronie użytkownika komponentu, tzn. generatora aplikacji konkretnego typu. Umożliwi to obsłużenie scenariusza, w którym pojedynczy element opisu dziedziny aplikacji posłuży za źródło generacji wielu plików wynikowych (np. definicja tabeli bazy danych, definicja klasy w kodzie źródłowym aplikacji i kod HTML będący częścią dokumentacji systemu mogą być wygenerowane na podstawie pojedynczej jednostki generacji będącej opisem encji). Odpowiedzialność wyodrębnienia jednostek generacji z pełnego opisu dziedziny zostanie zrzucona na użytkownika komponentu dlatego, że rdzeń generatora nie jest w stanie go zautomatyzować bez utraty elastyczności. Aby jednak obsłużyć najprostsze scenariusze, pominięcie implementacji tego kroku w aplikacji będącej użytkownikiem komponentu zaskutkuje potraktowaniem głównego obiektu (lub kolekcji obiektów) dziedziny jako jednostki (lub osobnych jednostek) generacji.

Uzyskane jednostki generacji bezpośrednio posłużą do wygenerowania plików wynikowych. Pojedyncza jednostka będzie mogła odpowiadać jednemu lub wielu plikom wynikowym.

### 5.2.4 Użycie szablonów do wygenerowania plików

Ostatnim krokiem będzie użycie jednostek generacji w celu wygenerowania plików wynikowych. Domyślny mechanizm generacji pliku wynikowego oparty będzie o wykorzystanie silnika generacji plików na podstawie szablonu generacji (patrz: sekcja 5.6).

Rdzeń generatora przekaże daną jednostkę generacji odpowiedniemu szablonowi, a wygenerowana treść zostanie umieszczona w odpowiednim pliku. Zadaniem użytkownika komponentu będzie dostarczenie zarówno szablonu generacji, jak i ścieżki, pod którą ma się znaleźć wygenerowany plik.

Aby zachować elastyczność, wykorzystywany silnik generacji będzie mógł zostać wymieniony na inny przez użytkownika generatora.

## 5.3 Organizacja plików źródłowych i wynikowych

Podstawową decyzją, którą należy podjąć w trakcie precyzowania założeń dotyczących pierwszego kroku generacji jest organizacja i format plików źródłowych, na których pracował będzie rdzeń narzędzia, a także organizacja plików, które będzie w stanie wygenerować. Jak wspomniano wyżej, od rdzenia oczekuje się jak największej elastyczności - dlatego powinien on wspierać kilka scenariuszy. Za przykład niech posłuży internetowy portal informacyjny.

### 5.3.1 Pojedynczy plik źródłowy

W tym scenariuszu całość dziedziny aplikacji (lub innych informacji o systemie) zawarta jest w pojedynczym pliku. Przykładem zastosowania może być pojedynczy skrypt SQL zawierający strukturę bazy danych używanej przez aplikację. Taki plik, oprócz swojego standardowego przeznaczenia, tj. konfigurowania bazy danych, pełniłby rolę źródła generatora *Code First*. Na jego podstawie generowane byłyby pliki zawierające definicje klas będących częścią implementacji modelu dziedziny w aplikacji.

Rysunek 5.1 obrazuje przykładową organizację plików portalu.

Źródło generacji:

`database_structure.sql`

Wynik generacji:

```
Model
├── User.cs
├── News.cs
├── Comment.cs
└── ...
```

Rysunek 5.1: Przykład organizacji plików przy generacji kilku plików wynikowych na podstawie pojedynczego pliku źródłowego.

### 5.3.2 Pojedynczy katalog z wieloma plikami źródłowymi

Kontynuując przykład, w miarę upływu czasu portal może rozrosnąć się na tyle, że wprowadzi możliwość prowadzenia blogów przez jego użytkowników. Wtedy może wystąpić potrzeba podzielenia struktury bazy danych na kilka plików - np. według nazw schematów (ang. *schema*), w których znajdują się poszczególne tabele. Wszystkie te pliki w dalszym ciągu byłyby źródłem dla generatora, a wynikowe klasy mogłyby być umieszczone w osobnych katalogach (podzielonych według nazw schematów, w których znajdują się odpowiadające im tabele).

Rysunek 5.2 obrazuje przykład.

Źródło generacji:

```
database_structure
├── dbo.sql
├── news.sql
└── blogs.sql
```

Wynik generacji:

```
Model
├── dbo
│   ├── User.cs
│   └── ...
├── news
│   ├── News.cs
│   ├── Comment.cs
│   └── ...
└── blogs
    ├── Post.cs
    ├── Comment.cs
    └── ...
```

Rysunek 5.2: Przykład organizacji plików przy generacji kilku katalogów wynikowych na podstawie wielu plików źródłowych (dbo - schemat wspólny, pozostałe - schematy właściwe obszarom, którymi zajmuje się portal).

### 5.3.3 Drzewo katalogów z wieloma plikami źródłowymi

W dłuższej perspektywie, w opisywanym przykładzie może pojawić się potrzeba wprowadzenia podkatalogów dla poszczególnych schematów. Pojedynczy podkatalog zawierałby osobne pliki zawierające definicje tabel, widoków i procedur składowanych obecnych w bazie danych. Rdzeń narzędzia generującego powinien być w stanie dotrzeć do wszystkich tych plików. Przykład takiej organizacji został przedstawiony na rysunku 5.3.

Innym przykładem wykorzystującym ten scenariusz jest sytuacja, w której pojedynczy plik wynikowy generowany jest na podstawie wielu plików źródłowych. Przykładem może być zorganizowanie opisu dziedziny aplikacji w taki sposób, aby informacje na temat każdego pola każdej encji umieszczone były w osobnym pliku. Rysunek 5.4 obrazuje przykład.

Źródło generacji:

```
database_structure
├── dbo
│   ├── tables.sql
│   ├── views.sql
│   └── procedures.sql
├── news
│   ├── tables.sql
│   ├── views.sql
│   └── procedures.sql
└── blogs
    ├── tables.sql
    ├── views.sql
    └── procedures.sql
```

Wynik generacji:

```
Model
├── dbo
│   ├── User.cs
│   ├── ...
├── news
│   ├── News.cs
│   ├── Comment.cs
│   ├── ...
└── blogs
    ├── Post.cs
    ├── Comment.cs
    └── ...
```


Rysunek 5.3: Przykład organizacji plików przy generacji wielu katalogów wynikowych na podstawie wielu katalogów źródłowych (procedury składowane nie są podmiotem generacji).

Taka organizacja może mieć zastosowanie w przypadku, gdy w systemie w wielu miejscach występują jedynie fragmenty encji (np. w licznych widokach bazy danych). Wtedy każde pole może wymagać skonfigurowania dla niego miejsc, w których występuje, czego skutkiem mogą być rozległe opisy każdego z pól. Opisy te najwygodniej byłoby przechowywać w osobnych plikach.


## 5.4 Sposób zdefiniowania dziedziny aplikacji

O ile założenie o elastyczności generatora powinno dopuszczać zdefiniowanie dziedziny aplikacji w dowolny sposób, używając dowolnego formatu plików zawierających opis poszczególnych elementów tej dziedziny, o tyle generator powinien obsługiwać pewien domyślny sposób formatowania. Poniżej przedstawiono kilka z możliwych wyborów:

Źródło generacji:




Wynik generacji:



Rysunek 5.4: Przykład organizacji plików przy generacji wielu katalogów wynikowych na podstawie wielu katalogów źródłowych. Pojedynczy plik wynikowy jest generowany na podstawie wielu plików źródłowych.

### 5.4.1 UML

Oczywistym wyborem sposobu opisu dziedziny aplikacji wydaje się być język UML [16], stworzony między innymi do tego właśnie celu. Do opisu przykładowej dziedziny posłużyć może diagram klas przedstawiony na rysunku 5.5.



Rysunek 5.5: Przykładowa dziedzina aplikacji przedstawiona na diagramie klas będącym częścią języka UML.

Trzeba jednak zauważyć, że taki opis nie jest wystarczająco elastyczny - posiada on zdefiniowany z góry zestaw atrybutów. Natomiast rzeczywiste scenariusze użycia generatora wymagać mogą atrybutów, których przewidzenie na etapie projektowania jego rdzenia jest niemożliwe. Przykładowo, do opisu encji mogą należeć takie atrybuty jak:

- opis encji, który powinien znaleźć się w dokumentacji systemu;
- wersja systemu, w której encja została wprowadzona;
- widoki bazy danych, których źródłem jest encja.

Diagram klas nie przewiduje przechowywania żadej z tych informacji.

Co więcej, podstawową jednostką diagramu klas UML jest encja, co samo w sobie jest ograniczeniem elastyczności. Opis dziedziny aplikacji tworzony przez użytkownika generatora może natomiast za podstawową jednostkę obierać na przykład pojedyncze pole encji (patrz: rysunek 5.4). Do opisu pojedynczego pola encji, oprócz jego nazwy i typu, mogą należeć takie atrybuty, jak:

- opis pola, który powinien znaleźć się w dokumentacji systemu;
- wersja systemu, w której pole zostało wprowadzone;
- widoki bazy danych, w których występuje pole.

Diagram klas nie przewiduje przechowywania żadej z tych informacji.

### 5.4.2 XML

Język XML [17] jest powszechnie używany do opisu dziedziny. Jest o niego oparty na przykład język WSDL (język definicji usług sieciowych, ang. *Web Services Description Language*) [18] stosowany do opisu kontraktów (ang. *contract*) realizowanych przez usługi sieciowe (ang. *web service*).

XML jest pozbawiony wad języka UML - można w nim zamodelować dowolne atrybuty. Tę samą dziedzinę, która została przedstawiona na diagramie klas języka UML (rysunek 5.5), ale wzbogaconą o niedostępne na tym diagramie atrybuty, przedstawia rysunek 5.6.

### 5.4.3 JSON

Język JSON [19] posiada zestaw cech upodabniający go do języka XML. Jest on jednak prostszy i bardziej zwięzły - nie jest to język znaczników, więc nazwy atrybutów nie są duplikowane w znaczniku otwierającym i zamykającym. JSON również jest szeroko stosowany do opisu dziedziny, na przykład do opisu metadanych usług sieciowych opartych o protokół OData [20].

Rysunek 5.7 przedstawia przykładowy opis dziedziny zapisany w tym języku.

### 5.4.4 YAML

Język YAML [21] jest pod względem użyteczności podobny do języków XML i JSON. Jest to język najbardziej zwięzły z przedstawionych, jednak nie jest on używany w żadnym popularnym standardzie.

Przykładowy opis dziedziny zapisany języku YAML został przedstawiony na rysunku 5.7.

```
<Entities>
  <Entity Name="User">
    <Description>The user of the system.</Description>
    <IntroducedIn>1.1</IntroducedIn>
    <Fields>
      <Field Name="FirstName">
        <Type>string</Type>
        <Description>The first name of the user.</Description>
      </Field>
      <Field Name="LastName">
        <Type>string</Type>
        <Description>The last name of the user.</Description>
      </Field>
    </Fields>
  </Entity>
  <Entity Name="News">
    <Description>The piece of news.</Description>
    <IntroducedIn>1.0</IntroducedIn>
    <Fields>
      <Field Name="Title">
        <Type>string</Type>
        <Description>The title of the piece of news.</Description>
      </Field>
      <Field Name="Content">
        <Type>string</Type>
        <Description>The content of the piece of news.</Description>
      </Field>
    </Fields>
  </Entity>
</Entities>
```

Rysunek 5.6: Przykładowa dziedzina aplikacji zapisana w języku XML.

#### 5.4.5 Domyślny język opisu dziedziny

Jako że język UML nie spełnia wymagań rdzenia generatora w zakresie elastyczności, domyślnie wspieranym językiem opisu dziedziny aplikacji będzie jeden z pozostałych trzech opisanych wyżej. Będzie to język JSON, za którym przemawiają następujące fakty:

- ma on najprostszą składnię za wszystkich trzech kandydatów;
- jest bardziej czytelny dla człowieka niż XML;
- jest szerzej znany i stosowany niż YAML.

Aby zachować elastyczność, język opisu dziedziny będzie jednak można łatwo wymienić.



```
[
  {
    "Name": "User",
    "Description": "The user of the system.",
    "IntroducedIn": "1.1"
    "Fields": [
      {
        "Name": "FirstName",
        "Type": "string",
        "Description": "The first name of the user.",
      },
      {
        "Name": "LastName",
        "Type": "string",
        "Description": "The last name of the user.",
      },
    ]
  },
  {
    "Name": "News",
    "Description": "The piece of news.",
    "IntroducedIn": "1.0",
    "Fields": [
      {
        "Name": "Title",
        "Type": "string",
        "Description": "The title of the piece of news.",
      },
      {
        "Name": "Content",
        "Type": "string",
        "Description": "The content of the piece of news.",
      },
    ]
  }
]
```

Rysunek 5.7: Przykładowa dziedzina aplikacji zapisana w języku JSON.

## 5.5 Czy wymagać stworzenia schematu definicji dziedziny aplikacji?

Kolejną decyzją jest wybór typu danych, do którego deserializoway będzie opis dziedziny aplikacji. Wyboru należy dokonać pomiędzy dwoma przeciwstawnymi podejściami:

```
---
- Name:      User
  Description: The user of the system.
  IntroducedIn: 1.1
  Fields:
    - Name:      FirstName
      Type:      string
      Description: The first name of the user.

    - Name:      LastName
      Type:      string
      Description: The last name of the user.

- Name:      News
  Description: The piece of news.
  IntroducedIn: 1.0,
  Fields:
    - Name:      Title
      Type:      string
      Description: The title of the piece of news.

    - Name:      Content
      Type:      string
      Description: The content of the piece of news.
...
```

Rysunek 5.8: Przykładowa dziedzina aplikacji zapisana w języku YAML.

1. Dane silnie typizowane, z czym wiąże się wymóg określenia schematu opisu dziedziny aplikacji. Konsekwencje tego wyboru:
  - wynikiem deserializacji opisu dziedziny aplikacji będzie obiekt konkretnego typu;
  - wystąpienie w opisie pola nieobecnego w schemacie dziedziny zostanie zignorowane lub spowoduje błąd deserializacji.
2. Dane dynamiczne; brak wymogu istnienia schematu opisu dziedziny. Konsekwencje wyboru:
  - wynikiem deserializacji opisu dziedziny będzie obiekt dynamiczny lub zbiór par klucz-wartość;
  - wystąpienie w opisie pola nieobecnego w schemacie będzie akceptowalne - pole takie znajdzie się w obiekcie powstałym w wyniku deserializacji.

Pierwsza możliwość wydaje się bardziej korzystna. Przemawiają za nią następujące zalety:

- generator będzie sprawdzał spójność opisu dziedziny aplikacji;
- ewentualne błędy opisu (na przykład tzw. literówki) zostaną wykryte na etapie deserializacji;
- szablony generacji będą mogły pracować na danych silnie typizowanych.

Domyślnie wspieranym podejściem będzie więc deserializacja opisu dziedziny do obiektu silnego typu. Aby jednak zachować elastyczność, możliwa będzie deserializacja do typu dynamicznego.

## 5.6 Wybór silnika do generacji kodu

Ostatnią decyzją w ramach założeń dotyczących rdzenia generatora jest wybór silnika generacji kodu (ang. *templating engine*) przez niego używanego. Domyślnie używany silnik wybrano spośród następujących możliwości:

### 5.6.1 XSLT

XSLT (Xml Stylesheets Transformations) [15] jest językiem generacji dowolnych plików tekstowych na podstawie plików XML. Jest to standard zaproponowany przez organizację W3C [22]. Jego zaletą jest to, że szablony generacji tworzone są w języku XML, co zwalnia programistę z potrzeby poznawania kolejnego języka. Jest on jednak mało czytelny, a wprowadzanie zmian w szablonie jest niewygodne.

### 5.6.2 Razor

Razor [23] jest silnikiem generacji tekstu stworzonym na potrzeby platformy ASP.NET MVC. Służy głównie do generacji kodu HTML, jednak może być używany w celu tworzenia dowolnych plików tekstowych.

Wadą tego wyboru - niezależną od samego silnika - jest to, że szablony Razor są powszechnie używane w typowych aplikacjach opartych o platformę ASP.NET MVC, a więc same mogą stanowić pliki wynikowe dla generatora. Stworzenie szablonu Razor generującego inny szablon Razor jest możliwe, ale taki szablon byłby bardzo nieczytelny - co dyskwalifikuje ten silnik.

### 5.6.3 T4

T4 [24] to silnik generacji tekstu wbudowany w środowisko programistyczne Microsoft Visual Studio. Jest on przeznaczony do generowania plików tekstowych dowolnego typu na podstawie danych przekazanych szablonowi.

Szablon T4 nie jest interpretowany, a kompilowany do kodu języka C#, co daje następujące korzyści:

- szybkość generacji tekstu jest większa niż w przypadku pozostałych silników;

- szablon może odwoływać się do bibliotek zewnętrznych i wywoływać ich metody (np. w celu pobrania potrzebnych danych z bazy danych);
- szablon może wywoływać inne szablony lub dziedziczyć po innym szablonie.

Taka integracja ze środowiskiem programistycznym i platformą .NET niesie za sobą dalsze konsekwencje:

- tworzenie szablonów jest ułatwione ze względu na podświetlanie i podpowiadanie składni (zarówno języka szablonu i jak korzystającego z niego kodu C#);
- silnik ten jest niedostępny dla programistów innych platform.

#### 5.6.4 Wybrany silnik

Ze względu na fakt, że zarówno rdzeń generatora jak i generator konkretnego typu aplikacji stworzone zostaną w oparciu o platformę .NET, silnikiem generacji domyślnie wspieranym przez rdzeń generatora będzie T4. Powodem tego wyboru jest łatwość tworzenia jego szablonów w środowisku Visual Studio.

Przykładowy szablon został przedstawiony na rysunku 5.9.

Podobnie jak w przypadku pozostałych podjętych decyzji, używany przez generator silnik będzie mógł być zastąpiony przez inny.

### 5.7 Podsumowanie

Wymagania dotyczące rdzenia generatora zostały skompletowane. Następnym krokiem jest sformułowanie założeń dotyczących generatora aplikacji konkretnego typu.

Szablon:

```
<#@ template language="C#" #>
<#@ parameter type="Sample.Schema.Entity" name="Entity" #>
namespace Sample
{
    /// <summary> <#= Entity.Description #> </summary>
    public class <#= Entity.Name #>
    {
        <# foreach (var field in Entity.Fields) { #>
            /// <summary> <#= field.Description #> </summary>
            public <#= field.Type #> <#= field.Name #> { get; set; }
        <# } #>
    }
}
```

Wynik:

```
namespace Sample
{
    /// <summary> The user of the system. </summary>
    public class User
    {
        /// <summary> The first name of the User. </summary>
        public string FirstName { get; set; }

        /// <summary> The last name of the User. </summary>
        public string LastName { get; set; }
    }
}
```

Rysunek 5.9: Przykładowy szablon T4 i wynikowy kod C#.

# Rozdział 6

## Sprecyzowanie typu generowanych aplikacji

Po zebraniu założeń dotyczących rdzenia narzędzia generującego aplikacje, nadszedł czas na wybór typu aplikacji, które będą generowane przez narzędzie.

### 6.1 Wybór typu aplikacji

Narzędzie powinno generować taki typ aplikacji, aby można było w pełni zbadać jego użyteczność i ocenić, na ile eliminuje ono duplikację. Aby było to możliwe, narzędzie powinno generować aplikacje, w których występuje dużo potencjalnych miejsc występowania duplikacji.

Wymaganie to spełniają aplikacje o architekturze wielowarstwowej (ang. *multi-tier architecture*, *n-tier architecture* [25]).

#### 6.1.1 Architektura wielowarstwowa


Architektura wielowarstwowa to taka, w której ogólne obszary przetwarzania danych w aplikacji są fizycznie rozdzielone pomiędzy osobne komponenty. Współpraca pomiędzy tymi komponentami jest zorganizowana w taki sposób, że komponent *A* może korzystać z funkcjonalności komponentu *B* tylko wtedy, gdy komponent *B* należy do warstwy logicznie umiejscowionej nie wyżej niż warstwa, do której należy komponent *A*.

Przykładem, a jednocześnie najpopularniejszą realizacją tej architektury jest architektura trójwarstwowa (ang. *three-tier architecture*), która wprowadza podział aplikacji na trzy warstwy:

1. Warstwa prezentacji (ang. *Presentation Layer*) - odpowiada za komunikację z użytkownikiem aplikacji (np. poprzez interfejs graficzny) lub innymi systemami (np. poprzez usługi sieciowe); jest to warstwa logicznie najwyższa;
2. Warstwa logiki biznesowej (ang. *Business Logic Layer*, *BLL*) - odpowiada za przetwarzanie danych zgodnie z wymaganiami funkcjonalnymi aplikacji;

3. Warstwa dostępu do danych (ang. *Data Access Layer, DAL*) - udostępnia mechanizmy odczytu i zapisu danych składowanych przez aplikację (np. w pamięci lub w bazie danych); jest to warstwa logicznie najniższa.

Współpracę pomiędzy warstwami architektury trójwarstwowej przedstawia diagram zamieszczony na rysunku 6.1.



Rysunek 6.1: Współpraca pomiędzy warstwami architektury trójwarstwowej [26].

W takiej architekturze elementy dziedziny aplikacji często mają swoje odwzorowanie w każdej z warstw, na przykład:

- jako obiekty modelu w warstwie dostępu do danych;
- jako obiekty biznesowe (ang. *business object*) [27] w warstwie logiki biznesowej;
- jako modele widoków (ang. *view model*) [28] interfejsu użytkownika lub obiekty transportu danych (ang. *Data Transfer Object, DTO*) [29] usług sieciowych w warstwie prezentacji.

To sprawia, że aplikacja o architekturze wielowarstwowej jest narażona na powszechne występowanie duplikacji wiedzy na temat dziedziny aplikacji, a tym samym dobrze nadaje się jako typ aplikacji generowanych przez narzędzie.

## 6.2 CQRS


Przypadkiem szczególnym architektury wielowarstwowej jest architektura CQRS (*Command Query Responsibility Segregation*) [30]. Zakłada ona podział wszystkich działań w aplikacji na dwa rodzaje:

- zapytanie (ang. *query*) - działanie polegające na pobraniu danych z bazy danych (lub innego źródła danych);
- komenda (ang. *command*) - działanie polegające na modyfikacji danych w bazie danych.

Działania te w architekturze CQRS są rozłączne. Ich wykonywaniem zajmują się dwa osobne modele danych aplikacji:

- model zapytań (ang. *Query Model*) - model przeznaczony do odczytu danych;
- model komend (ang. *Command Model*) - model przeznaczony do modyfikacji danych.

Modele te mogą być całkowicie rozłączne lub częściowo na siebie zachodzić. Koncepcyjny schemat tej architektury przedstawia rysunek 6.2.



Rysunek 6.2: Schemat architektury CQRS [31].

Podział odpowiedzialności pomiędzy komponenty przedstawia się następująco:

- model zapytań zajmuje się odczytywaniem danych z bazy danych;
- odpowiedzialnością modelu komend jest realizacja logiki biznesowej aplikacji, w tym weryfikacja poprawności danych, aktualizacja danych w bazie danych itd.;
- warstwa prezentacji (*UI*):
  - wyświetla dane pobrane z modelu zapytań za pośrednictwem interfejsów (*Service Interfaces*),



- przekazuje - w postaci komend - akcje wykonywane przez użytkownika do modelu komend.

Wprowadzenie podziału pomiędzy zapytanie i komendę niesie ze sobą dwie ważne zalety:

- skomplikowana dziedzina aplikacji może być podzielona na dwie prostsze dziedziny, co ułatwia jej zrozumienie i operowanie na niej;
- zapytania i komendy mogą być wykonywane równolegle, co poprawia wydajność aplikacji;
- zapytania są wykonywane na specjalnie przygotowanych dla nich danych (np. zmaterializowanych widokach bazy danych), co ma bardzo pozytywny wpływ na ich wydajność.

W parze z zaletami idą jednak wady:

- synchronizacja obu modeli w przypadku, gdy korzystają one z osobnych źródeł danych może być kłopotliwa; problem ten nie występuje na przykład wtedy, gdy model komend operuje na tabelach bazy danych, a model zapytań - na zmaterializowanych widokach, których źródłem danych są te tabele (synchronizacja modeli odbywa się wtedy automatycznie po stronie bazy danych);
- aby każde zapytanie mogło być obsłużone jak najszybciej, model jest w dużym stopniu zdenormalizowany.

Konsekwencją drugiej wady jest to, że w modelu zapytań masowo występuje duplikacja elementów dziedziny aplikacji. Jest to dobry powód do tego, aby generator generował aplikacje oparte właśnie o architekturę CQRS. Dodatkowo, wybór tej architektury stworzy okazję do przyjrzenia się innym problemom związanym z zastosowaniem architektury CQRS. Te problemy to:

1. Model komend i model zapytań częściowo na siebie zachodzą lub nawet model zapytań w całości zawiera model komend - rodzi to dwa pytania:
  - jak w tej sytuacji uniknąć duplikacji wiedzy na temat dziedziny aplikacji?
  - który model wybrać na “pojedynczą, jednoznaczną i autorytatywną” (patrz: Zasada “DRY” w rozdziale 2) reprezentację wiedzy o dziedzinie aplikacji?
2. Model komend może nie być nigdzie fizycznie przechowywany - komendy mogą bezpośrednio aktualizować zdenormalizowaną strukturę tabel bazy danych. Gdzie w takim przypadku należy umieścić wiedzę na temat encji należących do dziedziny aplikacji? Model zapytań nie zawiera przecież encji dziedziny, a tylko widoki na te encje.

Architektura CQRS często idzie w parze z wykorzystaniem wzorca Event Sourcing i baz danych typu NoSQL. Zagadnienia te zostaną opisane w kolejnych sekcjach.

## 6.3 Event Sourcing

Event Sourcing [32] jest wzorcem architektonicznym, który realizuje przechowywanie stanu aplikacji poprzez przechowywanie wszystkich zdarzeń (ang. *event*), które zaszły w systemie od początku jego działania aż do stanu obecnego. Terminem “zdarzenie” określa się tutaj dowolną akcję, która ma wpływ na stan systemu.

### 6.3.1 Cechy zdarzenia

Zdarzenie posiada następujące cechy [33]:

- ma ono znaczenie dopiero wtedy, kiedy rzeczywiście wystąpi (np. “Post został skomentowany”) - zdarzeń przyszłych nie bierze się pod uwagę;
- jest ono niezmiennie - jako że zdarzenie zaszło w przeszłości, nie może ono zostać zmienione ani cofnięte; jego skutki mogą jednak zostać zniwelowane przez inne zdarzenie (np. “Komentarz został usunięty”);
- powinno ono mieć znaczenie biznesowe, a nie implementacyjne - opisanie zajścia zdarzenia słowami: “Do tabeli Comment dodano nowy rekord” niesie ze sobą mniejszą wartość biznesową niż: “Post został skomentowany”.
- zazwyczaj zawiera ono informacje na temat kontekstu, w którym zaszło (np. “Użytkownik *X* dodał komentarz *Y* pod postem *Z*”, “Moderator *W* usunął komentarz *Y*”);
- informacja o zajściu zdarzenia jest informacją jednokierunkową od nadawcy (ang. *publisher*) do odbiorcy (ang. *subscriber*) lub wielu odbiorców; reakcja odbiorcy na zdarzenie nie jest bezpośrednio znana nadawcy.

Rejestrowanie zdarzeń odbywa się poprzez stworzenie obiektu opisującego daną akcję i zapisanie go w systemie. Zdarzenia rejestrowane są w dzienniku zdarzeń (ang. *event log* lub *event storage*). Za reagowanie na zdarzenia, a w efekcie faktyczną zmianę stanu systemu odpowiadają wyznaczone do tego obiekty implementujące odpowiednie procedury obsługi (ang. *event handlers*). Obiekty te pobierają nieprzetworzone zdarzenia z dziennika zdarzeń i wykonują procedury. Pojedyncze zdarzenie może zostać przetworzone przez wiele takich obiektów, wykonujących wiele osobnych modyfikacji stanu systemu.

### 6.3.2 Zalety i wady wzorca

Wzorec Event Sourcing wprowadza następujące zalety:

- dziennik zdarzeń dostarcza informacji o historii działań użytkowników systemu - informacje te mogą być przydatne podczas szukania przyczyn wystąpienia błędów;
- aplikację można łatwo usunąć i przywrócić do poprzedniego stanu poprzez zarejestrowanie wszystkich zdarzeń od nowa (np. podczas przenoszenia jej na inną maszynę);

- stan aplikacji można łatwo cofnąć do dowolnego punktu w czasie - wystarczy wyczyścić stan aplikacji i zarejestrować od nowa wszystkie zdarzenia, które zaszły przed wybranym punktem w czasie (może to ułatwić szukanie przyczyn wystąpienia błędów);
- w razie wykrycia zdarzenia będącego przyczyną wystąpienia błędu, można usunąć to zdarzenie z dziennika i zarejestrować od nowa wszystkie zdarzenia, które nastąpiły po nim; na podobnej zasadzie można skorygować kolejność zdarzeń zarejestrowanych w złej kolejności (z tej zalety powinno się korzystać jedynie w sytuacjach awaryjnych, ponieważ narusza ona cechę zdarzeń mówiącą o ich niezmierności).

Wady:

- implementacja dziennika zdarzeń nie jest łatwa - powinna ona gwarantować, że zdarzenia zostaną wpisane do dziennika w kolejności ich zgłaszania (co nie jest oczywiste w aplikacjach wielowątkowych);
- z reguły reakcja na zdarzenie odbywa się asynchronicznie względem procesu zgłaszającego jego zajście - zmiany stanu systemu nie są więc widoczne natychmiast po zajściu zdarzenia; zjawisko to jest widoczne na przykład w serwisie YouTube [34] - zdarzenie "Obejrzano film" jest przetwarzane znacznie wolniej niż zdarzenie "Dodano komentarz" (wyświetlenia filmu sprawdzane są pod kątem fałszywych wyświetleń mających na celu sztuczne zwiększenie popularności filmu [35]), co skutkuje wyświetleniem większej liczby komentarzy niż liczby wyświetleń pod danym filmem (jeśli komentarzy i wyświetleń jest odpowiednio dużo);
- odtwarzanie stanu systemu, w którym zarejestrowano tysiące zdarzeń może trwać bardzo długo (rozwiązaniem tego problemu jest tworzenie migawek (ang. *snapshot*) systemu przechowujących stan systemu co ileś zdarzeń);
- zmiany w kodzie źródłowym systemu mogą powodować, że dawno zarejestrowane zdarzenia przestaną być niekompatybilne z nową wersją systemu.

### 6.3.3 Przykłady aplikacji wykorzystujących Event Sourcing

Aby łatwiej zrozumieć działanie wzorca, garść przykładów aplikacji używanych na co dzień, które są oparte o Event Sourcing lub częściowo go wykorzystują:

- systemy kontroli wersji - dziennik zdarzeń przechowuje zmiany dokonywane na plikach znajdujących się w wersjonowanym katalogu;
- edytory tekstu i edytory graficzne - dziennik zdarzeń przechowuje zmiany dokonywane na edytowanym pliku.

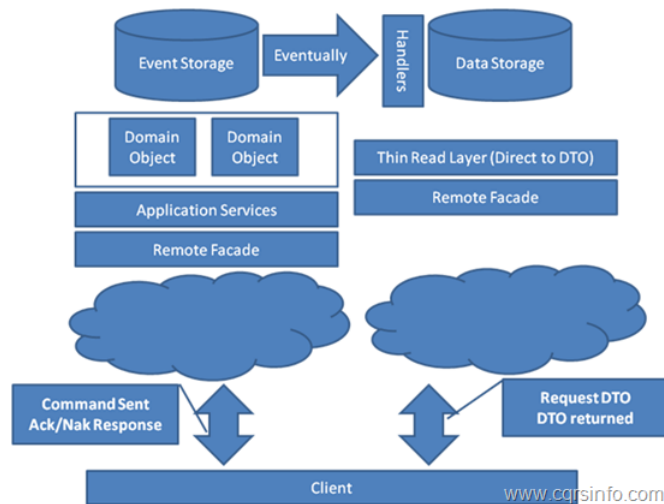
Wzorzec ten ma jednak zastosowanie nie tylko w aplikacjach użytkowych. W połączeniu z wzorcem CQRS, sprawdza się także w aplikacjach klasy enterprise.

### 6.3.4 Współpraca z CQRS

Zasady działania wzorca Event Sourcing w systemie opartym o architekturę CQRS są następujące [36]:

- rolę modelu komend pełni dziennik zdarzeń - jedynym zadaniem komend jest zarejestrowanie zdarzenia w dzienniku;
- stan systemu jest przechowywany w modelu zapytań;
- za synchronizację modelu zapytań z modelem komend odpowiadają procedury obsługi zdarzeń (*event handlers*) - synchronizacja ta odbywa się asynchronicznie;
- wzorzec Event Sourcing nie ma wpływu na warstwę prezentacji systemu.

Współpraca ta została schematycznie przedstawiona na rysunku 6.3.



Rysunek 6.3: Współpraca wzorca Event Sourcing z architekturą CQRS [37].

## 6.4 NoSQL

Bazy danych typu NoSQL (ang. *Not Only SQL*) odrzucają praktykę składowania danych w tabelarycznej, opartej na relacjach, ustrukturyzowanej formie będącej podstawą relacyjnych baz danych. Zamiast tego składują dane w innych, bardziej elastycznych postaciach, na przykład grafu lub zbioru par klucz-wartość. Pozwala to na wykonywanie niektórych operacji szybciej, niż są one wykonywane przez relacyjne bazy danych. Nie jest to jednak rozwiązanie bezwzględnie lepsze od relacyjnych baz danych - niektóre operacje są wykonywane wolniej w bazach typu NoSQL, niż w bazach relacyjnych.

Bazy danych typu NoSQL są nastawione na przechowywanie bardzo dużych ilości danych. Tym, co odróżnia je od baz relacyjnych jest fakt, że zazwyczaj domyślnie wspierają one rozproszenie danych pomiędzy wiele maszyn. Zapewnia to łatwą poziomą skalowalność systemów z nich korzystających.

### 6.4.1 Dostępne bazy NoSQL

Bazy danych typu NoSQL są tworzone pod kątem konkretnych problemów, jakie mają rozwiązywać. Dlatego istnieje wiele takich baz, które różnią się wydajnością bądź oferowanymi funkcjonalnościami. Można je podzielić ze względu na model przechowywania danych. Najczęściej stosowane modele to:

#### Rodzina kolumn

Rodzina kolumn (ang. *column family*, *wide column*) jest modelem najbardziej przypominającym tabele w relacyjnej bazie danych. Dane przechowywane są w wierszach, które składają się z kolumn wraz z przypisanymi im wartościami. Pojedynczy wiersz może składać się z bardzo dużej liczby kolumn. W odróżnieniu od relacyjnych baz danych, wiersz nie musi posiadać wszystkich kolumn wchodzących w skład rodziny i może posiadać kolumny nienależące do rodziny. Każda wartość przypisana do dajen kolumny wchodzącej w skład rodziny musi jednak być określonego dla tej kolumny typu.

W odróżnieniu od baz relacyjnych bazy oparte o rodziny kolumn nie wspierają relacji pomiędzy tabelami (rodzinami kolumn). Aby osiągnąć satysfakcjonującą wydajność przeszukiwania, przechowuje się w nich dane o wysokim stopniu denormalizacji. Przykłady baz danych przechowujących rodziny kolumn:

- Hadoop [38] - platforma stworzona w technologii Java, wykonująca obliczenia na dużych ilościach danych realizowane przez wiele rozproszonych aplikacji, służy przede wszystkim do przetwarzania danych, a nie do ich składowania;
- Cassandra [39] - stworzona w technologii Java baza danych, której główne cele to skalowalność, wysoka wydajność i brak pojedynczego punktu awarii (ang. *Single Point of Failure*, *SPOF*);
- Amazon SimpleDB [40] - komercyjna baza danych nastawiona na prostotę użytkowania i zarządzania.

#### Zbiór par klucz-wartość

Para klucz-wartość (ang. *key-value pair*) jest zdecydowanie najprostszą strukturą danych używaną w bazach danych typu NoSQL. Przechowywane w postaci zbiorów takich par dane nie są w żaden sposób ustrukturyzowane. Pary klucz-wartość są podstawą dla innych modeli danych, na przykład rodzin kolumn, gdzie wiersze składają się z par kolumna-wartość. Są więc najbardziej elastycznym modelem, ale zazwyczaj oferującym ubogi zestaw funkcjonalności.

Przykłady baz przechowujących pary klucz-wartość to:

- DynamoDB [44] - baza danych będąca w stanie wydajnie działać pod bardzo dużym obciążeniem, jej kluczowymi celami są wydajność i skalowalność; stworzona w technologii Java;
- Azure Table Storage [45] - baza danych wspierająca przechowywanie danych w tabelarycznej, ustrukturyzowanej formie; stworzona na platformie .Net;

- Redis [46] - napisana w języku C wydajna baza danych wspierająca przechowywanie złożonych struktur takich jak listy, kolejki czy posortowane zbiory.

## Graf

Niektóre bazy danych typu NoSQL za model danych obierają graf. Takie bazy nazywamy grafowymi bazami danych (ang. *graph databases*).

Węzłem grafu może być dowolny obiekt (np. zbiór par klucz-wartość), a krawędź może łączyć dwa dowolne węzły. Pojedyncza krawędź reprezentuje dowolną relację pomiędzy węzłami. Model ten jest więc bardzo elastyczny.

Zaletą grafu jest to, że, podobnie jak relacja, jest on strukturą danych o silnym podłożu matematycznym. Istnieje więc wiele wydajnych algorytmów operujących na tej strukturze (np. algorytmy wyszukiwania ścieżek), co sprawia, że struktura ta bardzo dobrze nadaje się do modelowania wszelkiego rodzaju danych przestrzennych (np. map) lub innych sieci (np. zbiorów użytkowników portali społecznościowych, gdzie wierzchołek reprezentuje osobę, a krawędź - relację "zna").

Do grafowych baz danych należą:

- Neo4J [47] - najpopularniejsza grafowa baza danych, cechuje się wysoką wydajnością i skalowalnością; wspiera mechanizm transakcji; stworzona w technologii Java;
- TITAN [48] - baza danych wykorzystująca inne rozwiązania, takie jak Cassandra, korzystając z wymiennych mechanizmów; stworzona w technologii Java;
- Trinity [49] - stworzona na platformie .Net baza danych wspierająca wygodne, deklaratywne modelowanie i przeszukiwanie danych.

## Dokument

Dokument (ang. *document*) jest typem danych, który z założenia reprezentuje duże porcje danych, z których tylko fragmenty są udostępniane na potrzeby pojedynczych zapytań. Dokumenty mogą posiadać dowolną strukturę, na co pozwala format, w jakim są przechowywane (np. XML lub JSON).

Bazy danych przechowujące dokumenty (ang. *document-oriented databases*) są więc przystosowane do przechowywania i przeszukiwania dużych jednostek danych. Do baz tego rodzaju należą:

- MongoDB [41] - umożliwia wygodne przeszukiwanie danych i tworzenie indeksów na dowolnych ich atrybutach, wspiera automatyczne dzielenie danych pomiędzy wiele maszyn (ang. *sharding*); stworzona w języku C++;
- CouchDB [42] - stworzona w języku Erlang baza danych udostępniająca przechowywane dane poprzez protokół HTTP; nastawiona na wykorzystanie w aplikacjach webowych i mobilnych;
- RavenDB [43] - baza danych umożliwiająca wykonywanie dowolnych operacji (np. przebudowy struktury) bez potrzeby zatrzymywania korzystających z niej aplikacji i udostępniająca wygodny sposób przeszukiwania danych; oparta na platformie .Net.

## 6.4.2 Wybrana baza typu NoSQL

Spośród dostępnych baz danych typu NoSQL należy wybrać jedną, która będzie używana przez aplikacje generowane przez narzędzie. Wydaje się, że z mechanizmem generacji dziedziny aplikacji najlepiej komponują się bazy za model danych obierające rodziny kolumn. Model ten jest najbardziej zbliżony do klasycznego modelu relacyjnego - dobrze nadaje się więc do przechowywania ustrukturyzowanej dziedziny aplikacji, a sama struktura bazy danych może być jednym z generowanych artefaktów;

Współpraca takiej bazy danych z architekturą CQRS i wzorcem Event Sourcing wyglądać będzie następująco:

- baza typu NoSQL pełnić będzie rolę modelu zapytań (komponent *Data Storage* na rysunku 6.3);
- model zapytań będzie w dużym stopniu zdenormalizowany, a więc przystosowany do przechowywania go w postaci rodzin kolumn;
- procedury obsługi zdarzeń będą modyfikować dane zawarte w tej bazie;
- wykorzystanie tej bazy nie będzie miało wpływu na model komend i dziennik zdarzeń - zdarzenia mogą, ale nie muszą być przechowywane w tej bazie.

Spośród baz danych opartych o model rodziny kolumn najbardziej popularna jest Cassandra. Przemawia za tym jej wysoka wydajność i skalowalność potwierdzona w badaniach [50]. Dlatego to właśnie z tej bazy korzystać będą wygenerowane aplikacje.

## 6.5 Cassandra

### 6.5.1 Architektura

węzły, klastry, redundancja, replikacja

### 6.5.2 Model danych

Cassandra przechowuje dane w postaci rodziny kolumn (patrz: sekcja 6.4.1) [51]. Od wersji 2.0 Każdy wiersz rodziny jest identyfikowany poprzez klucz główny (ang. *primary key*). W odróżnieniu od tabel w bazach relacyjnych, każda rodzina kolumn musi posiadać klucz główny. Należy podkreślić, że rodziny kolumn nie mogą posiadać znanych w bazach relacyjnych kluczy obcych (ang. *foreign key*) - kolumn wskazujących na inne rodziny.

Strukturę pojedynczego wiersza rodziny przedstawia rysunek 6.4.

Wiersze należące do tej samej rodziny przechowywane są w kolejności posortowanej według wartości jej klucza głównego. Kolumny należące do wiersza sortowane są według ich nazw.

Row key1	Column Key1	Column Key2	Column Key3	...
	Column Value1	Column Value2	Column Value3	
⋮				

Rysunek 6.4: Schemat modelu danych przechowywanych przez bazę Cassandra (*Row key* - wartość klucza głównego) [51].

## Superkolumny

Klucz główny rodziny może składać się z wielu kolumn. W takim przypadku pierwszą z kolumn wchodzących w skład klucza głównego nazywa się kluczem partycjonującym (ang. *partition key*). Pozostałe kolumny klucza głównego nazywa się superkolumnami (ang. *Super Column*). Strukturę wiersza należącego do rodziny kolumn posiadającej superkolumnę przedstawia rysunek 6.5.

Row key1	Super Column key1			Super Column key2			...
	Subcolumn Key1	Subcolumn Key2	...	Subcolumn Key3	Subcolumn Key4	...	
	Column Value1	Column Value2		Column Value3	Column Value4		
⋮							

Rysunek 6.5: Schemat rodziny kolumn posiadającej superkolumnę (*Super Column key* - wartość superkolumny) [51].

Superkolumny, podobnie jak klucz partycjonujący sortowane są według ich wartości - różnica polega na tym, że klucze partycjonujące sortowane są w obrębie całej rodziny kolumn, a superkolumny - w obrębie pojedynczego wiersza.

## Wartości kolumn

Wartościami kolumn mogą być różnego rodzaju wartości skalarne znane z baz relacyjnych, takie jak napisy (*text*, *ascii*), liczby całkowite (*int*, *bigint*) lub zmiennoprzecinkowe (*float*, *double*), czy wartości logiczne (*boolean*).

Jednakże w odróżnieniu od baz relacyjnych, wartościami kolumn mogą być również kolekcje: lista (*list*), zbiór unikalnych elementów (*set*) i mapa par klucz-wartość (*map*). Kolekcje mają następujące ograniczenia [52]:

- maksymalny rozmiar pojedynczego elementu kolekcji wynosi 64 KB;
- kolekcje są odczytywane i zwracane w całości - dlatego nie powinny zawierać dużej ilości elementów.



## Indeksy

Domyślnie, rodzina kolumn może być przeszukiwana jedynie po wartościach jej klucza partycjonującego. Aby móc przeszukiwać wiersze rodziny po wartościach innych kolumn (w tym superkolumn), należy stworzyć na nich indeksy.

Indeks (ang. *index*) to, podobnie jak w relacyjnych bazach danych, osobna (nie będąca częścią rodziny kolumn) struktura danych przechowująca posortowane wartości indeksowanych kolumn wraz ze wskazaniem na wiersze, do których te wartości należą.

Pojedynczy indeks przechowuje tylko wartości kolumn należących do wierszy, które znajdują się w jego węźle.

### 6.5.3 CQL

Do przeszukiwania i modyfikowania danych przechowywanych w bazie danych Cassandra służy język CQL (Cassandra Query Language). Jest on podobny do języka SQL, jednak

```
CREATE TABLE "User" (  
  "UserName" text,  
  "FirstName" text,  
  "LastName" text,  
  PRIMARY KEY ("UserName")  
);  
  
CREATE INDEX ON "User" ("LastName");
```

Rysunek 6.6: Komendy języka CQL tworzące rodzinę kolumn o nazwie *User* i kluczu głównym *UserName*, a także indeks na kolumnie *LastName* tej rodziny.

6.7

```
INSERT INTO "User" ("UserName", "FirstName", "LastName")  
VALUES ('JanKowalski', 'Jan', 'Kowalski');
```

Rysunek 6.7: Komenda języka CQL rejestrująca użytkownika “JanKowalski”.

6.8

```
SELECT * FROM "User"  
WHERE "LastName" = 'Kowalski';
```

Rysunek 6.8: Komenda języka CQL wyszukująca użytkowników o nazwisku “Kowalski”.

no FKs -i no joins no subquery

# Rozdział 7

## Implementacja generatora aplikacji pojedynczego typu

- Ogólnie nie chodzi o to, żeby w ogóle nie pisać nazw klas / właściwości - tylko o to, żeby nie trzeba było pamiętać o wszystkich miejscach, gdzie dana encja jest używana.
- czy w ogóle generować schemat bazy danych (no schema) (?)
- wybrać sposób definicji dziedziny
- że będzie schema
- ale że schema powinna być w jednym miejscu - będzie jako klasa w kodzie
- wybór formatu
- uml, emf się nie nadają - operują na encjach, a nie na polach
- xml albo json, bez różnicy - czytelniejszy i bardziej intuicyjny wydaje się JSON (xml ma atrybuty i węzły zagnieżdżone - nie wiadomo czego użyć)
- zdefiniowanie schematu opisu dziedziny na potrzeby CQRS
  - PresentIn
- Wybrór klienta Cassandra (?)
- Sformułowanie przykładu aplikacji
- Zapisanie schemy w JSONie
- Implementacja szablonów
- Implementacja kolejnych modułów aplikacji
  - DAL (repozytorium bazowe zahardkodowane, konkretnych nie da się wygenerować)

- BLL (obsługa zdarzeń zahardkodowana, da się wygenerować EventHandlery)
- WEB (Nancy, da się wygenerować ViewModele, formy)

Założenia dotyczące całości:

- generator ma generować dziedzinę aplikacji CQRS wykorzystującą Cassandrę:
  - schemat DLL
  - klasy C#: model Read, model Write
  - dokumentacja HTML
- ...

# Rozdział 8

## Ocena rozwiązania

- co dało się wygenerować, a co nie
- jakiej duplikacji udało się uniknąć
- jak łatwo wprowadza się zmiany w aplikacji
  - problem: jak obsłużyć zmiany struktury bazy danych? (migracje)
- ile pracy wymagałoby dodanie nowej funkcjonalności (API, eksport do arkusza) - przykład?
- jaką inną aplikację można wygenerować (przykład)

# Rozdział 9

## Podsumowanie

- Wnioski

# Bibliografia

- [1] *The Pragmatic Programmer*. Hunt A., Thomas D. Addison-Wesley. Westford 2013. ISBN 0-201-61622-X. *The Evils of Duplication*, s. 26-33.
- [2] *The Pragmatic Programmer*. Hunt A., Thomas D. Addison-Wesley. Westford 2013. ISBN 0-201-61622-X. *Software Entropy*, s. 4-6.
- [3] *Duplication in Software* [online]. Just Software Solutions. <http://www.justsoftwaresolutions.co.uk/design/duplication.html> [dostęp: lipiec 2014].
- [4] *Repetition* [online]. The Bad Code Spotter's Guide. Diomidis Spinellis. <http://www.informit.com/articles/article.aspx?p=457502&seqNum=5> [dostęp: lipiec 2014].
- [5] *Continuous delivery* [online]. ThoughtWorks. <http://www.thoughtworks.com/continuous-delivery> [dostęp: lipiec 2014].
- [6] *Entity Framework* [online]. CodePlex. <https://entityframework.codeplex.com/> [dostęp: lipiec 2014].
- [7] *SqlMetal.exe (Code Generation Tool)* [online]. Microsoft Developer Network. [http://msdn.microsoft.com/pl-pl/library/bb386987\(v=vs.110\).aspx](http://msdn.microsoft.com/pl-pl/library/bb386987(v=vs.110).aspx) [dostęp: lipiec 2014].
- [8] *The Web framework for perfectionists with deadlines* [online]. django. <https://www.djangoproject.com/> [dostęp: lipiec 2014].
- [9] *Hibernate. Everything data.* [online]. Hibernate. <http://http://hibernate.org/> [dostęp: lipiec 2014].
- [10] *Doxygen: Main Page* [online]. Doxygen. <http://www.stack.nl/~dimitri/doxygen/> [dostęp: lipiec 2014].
- [11] *Javadoc Tool Homepage* [online]. Oracle. <http://www.oracle.com/technetwork/java/javase/documentation-135444.html> [dostęp: lipiec 2014].
- [12] *XML Documentation* [online]. Microsoft Developer Network. [http://msdn.microsoft.com/en-us/library/b2s063f7\(vs.71\).aspx](http://msdn.microsoft.com/en-us/library/b2s063f7(vs.71).aspx) [dostęp: lipiec 2014].
- [13] *pydoc — Documentation generator and online help system* [online]. Python v2.7.8 documentation. <https://docs.python.org/2/library/pydoc.html> [dostęp: lipiec 2014].

- [14] *Automatic programming* [online]. Wikipedia, the free encyclopedia. [http://en.wikipedia.org/wiki/Automatic\\_programming](http://en.wikipedia.org/wiki/Automatic_programming) [dostęp: lipiec 2014].
- [15] *XSL Transformations (XSLT) Version 2.0* [online]. W3C. <http://www.w3.org/TR/xslt20/> [dostęp: lipiec 2014].
- [16] *Unified Modeling Language™(UML®)* [online]. Object Management Group. <http://www.uml.org/> [dostęp: lipiec 2014].
- [17] *Extensible Markup Language (XML)* [online]. W3C. <http://www.w3.org/XML/> [dostęp: lipiec 2014].
- [18] *Web Services Description Language (WSDL) 1.1* [online]. W3C. <http://www.w3.org/TR/wsdl> [dostęp: lipiec 2014].
- [19] *Introducing JSON* [online]. Ecma International. <http://json.org/> [dostęp: lipiec 2014].
- [20] *Open Data Protocol* [online]. OData. <http://www.odata.org/> [dostęp: lipiec 2014].
- [21] *The Official YAML Web Site* [online]. Evans C. <http://www.yaml.org/> [dostęp: lipiec 2014].
- [22] *World Wide Web Consortium (W3C)* [online]. W3C. <http://www.w3.org/> [dostęp: lipiec 2014].
- [23] *RazorEngine* [online]. GitHub. <https://github.com/Antaris/RazorEngine> [dostęp: lipiec 2014].
- [24] *Code Generation and T4 Text Templates* [online]. Microsoft Developer Network. <http://msdn.microsoft.com/pl-pl/library/bb126445.aspx> [dostęp: lipiec 2014].
- [25] *N-Tier Data Applications Overview* [online]. Microsoft Developer Network. <http://msdn.microsoft.com/en-us/library/bb384398.aspx> [dostęp: lipiec 2014].
- [26] *Three tier architecture in asp.net* [online]. Dot Net Peoples. <http://dotnetpeoples.blogspot.com/2011/04/three-tier-architecture-in-aspnet.html> [dostęp: lipiec 2014].
- [27] *Business object* [online]. Wikipedia, the free encyclopedia. [http://en.wikipedia.org/wiki/Business\\_object](http://en.wikipedia.org/wiki/Business_object) [dostęp: lipiec 2014].
- [28] *View model* [online]. Wikipedia, the free encyclopedia. [http://en.wikipedia.org/wiki/View\\_model](http://en.wikipedia.org/wiki/View_model) [dostęp: lipiec 2014].
- [29] *Data Transfer Object* [online]. Microsoft Developer Network. <http://msdn.microsoft.com/en-us/library/ms978717.aspx> [dostęp: lipiec 2014].
- [30] *Exploring CQRS and Event Sourcing* Betts D., Domínguez J., Melnik G., Simonazzi F., Subramanian M. Microsoft. 2012. ISBN 978-1-62114-016-0.
- [31] *CQRS* [online]. Fowler M. <http://martinfowler.com/bliki/CQRS.html> [dostęp: lipiec 2014].

- [32] *Event Sourcing Pattern* [online]. Microsoft Developer Network. <http://msdn.microsoft.com/en-us/library/dn589792.aspx> [dostęp: lipiec 2014].
- [33] *Introducing Event Sourcing* [online]. Microsoft Developer Network. <http://msdn.microsoft.com/en-us/library/jj591559.aspx> [dostęp: lipiec 2014].
- [34] *YouTube* [online]. YouTube. <https://www.youtube.com/> [dostęp: lipiec 2014].
- [35] *Why do YouTube views freeze at 301?* [online]. Numberphile. YouTube. <https://www.youtube.com/watch?v=olkhgagvrjI> [dostęp: lipiec 2014].
- [36] *CQRS and Event Sourcing* [online]. Wordpress. <http://cqrs.wordpress.com/documents/cqrs-and-event-sourcing-synergy/> [dostęp: lipiec 2014].
- [37] *CQRS Info* [online]. CQRS Info. <http://www.cqrsinfo.com/> [dostęp: lipiec 2014].
- [38] *Welcome to Apache™Hadoop®!* [online]. The Apache Software Foundation. <http://hadoop.apache.org/> [dostęp: lipiec 2014].
- [39] *The Apache Cassandra Project* [online]. The Apache Software Foundation. <https://cassandra.apache.org/> [dostęp: lipiec 2014].
- [40] *Amazon SimpleDB* [online]. Amazon Web Services. <http://aws.amazon.com/simplydb/> [dostęp: lipiec 2014].
- [41] *MongoDB* [online]. MongoDB. <http://www.mongodb.org/> [dostęp: lipiec 2014].
- [42] *Apache CouchDB* [online]. The Apache Software Foundation. <http://couchdb.apache.org/> [dostęp: lipiec 2014].
- [43] *Raven DB* [online]. GitHub. <https://github.com/ravendb/ravendb> [dostęp: lipiec 2014].
- [44] *Amazon DynamoDB* [online]. Amazon Web Services. <http://aws.amazon.com/dynamodb/> [dostęp: lipiec 2014].
- [45] *Table Service REST API* [online]. Microsoft Developer Network. <http://msdn.microsoft.com/en-us/library/dd179423.aspx> [dostęp: lipiec 2014].
- [46] *Redis* [online]. Citrusbyte. <http://redis.io/> [dostęp: lipiec 2014].
- [47] *Neo4j - The World's Leading Graph Database* [online]. Neo Technology. <http://www.neo4j.org/> [dostęp: lipiec 2014].
- [48] *Titan* [online]. GitHub. <https://github.com/thinkaurelius/titan/wiki> [dostęp: lipiec 2014].
- [49] *Trinity - Microsoft Research* [online]. Microsoft Research. <http://research.microsoft.com/en-us/projects/trinity/> [dostęp: lipiec 2014].



- [50] *Solving Big Data Challenges for Enterprise Application Performance Management* [online]. Rabl T., Sadoghi M., Jacobsen H. [http://vldb.org/pvldb/vol5/p1724\\_tilmanrabl\\_vldb2012.pdf](http://vldb.org/pvldb/vol5/p1724_tilmanrabl_vldb2012.pdf) [dostęp: lipiec 2014].
- [51] *Cassandra Data Modeling Best Practices, Part 1* [online]. Patel J. eBay tech blog. <http://www.ebaytechblog.com/2012/07/16/cassandra-data-modeling-best-practices-part-1/> [dostęp: lipiec 2014].
- [52] *Using collections* [online]. DataStax CQL 3.0 Documentation. [http://www.datastax.com/documentation/cql/3.0/cql/cql\\_using/use\\_collections\\_c.html](http://www.datastax.com/documentation/cql/3.0/cql/cql_using/use_collections_c.html) [dostęp: lipiec 2014].

## OŚWIADCZENIE

Oświadczam, że Pracę Dyplomową pod tytułem “[TYTUŁ]”, którą kierował dr inż. Jakub Koperwas, wykonałem samodzielnie, co poświadczam własnoręcznym podpisem.

.....

Michał Aniserowicz